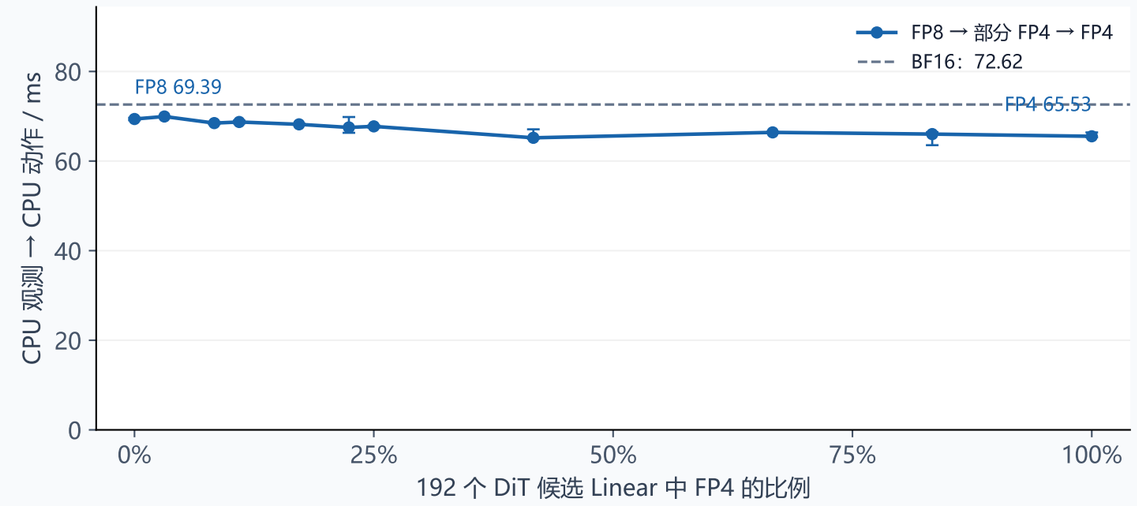
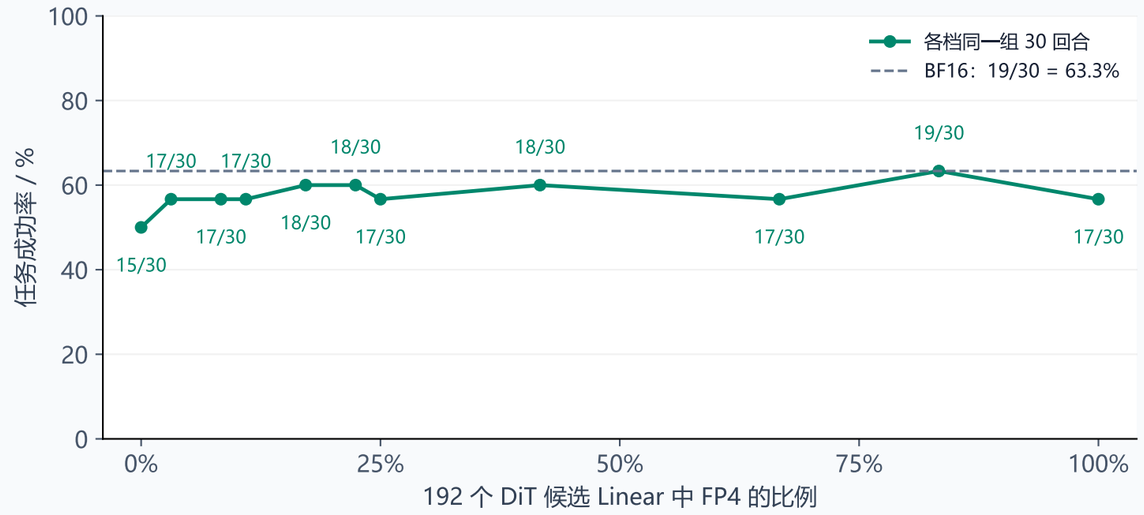
Thor 渐进量化：完整 360 回合初步验证

12 档性能数据齐全；12 档 × 10 任务 × 3 固定初始状态全部完成。质量完成于北京时间 2026-10-14 02:05:19。

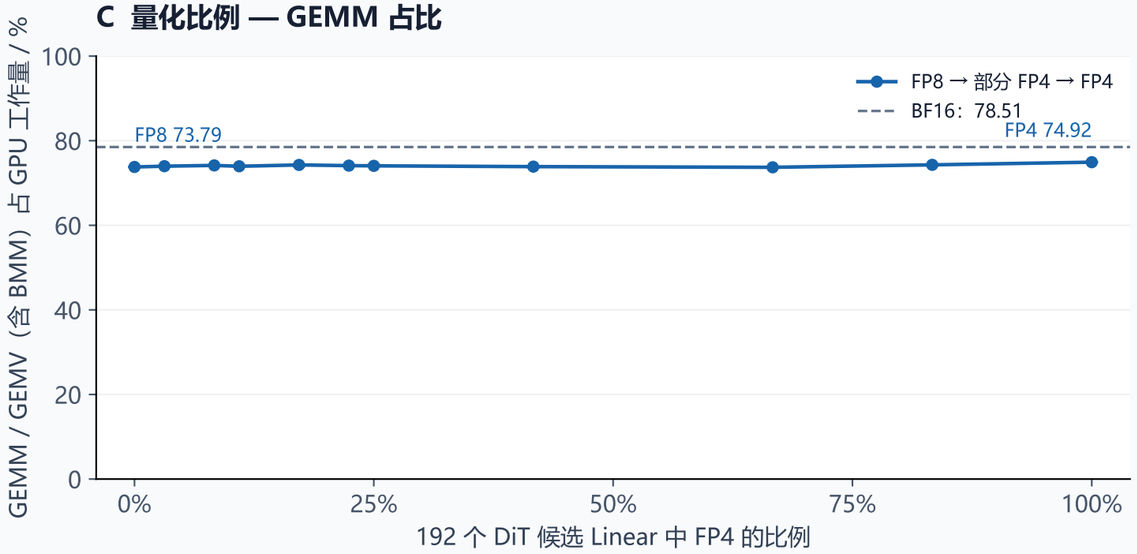
A 量化比例 — 单次完整调用延迟



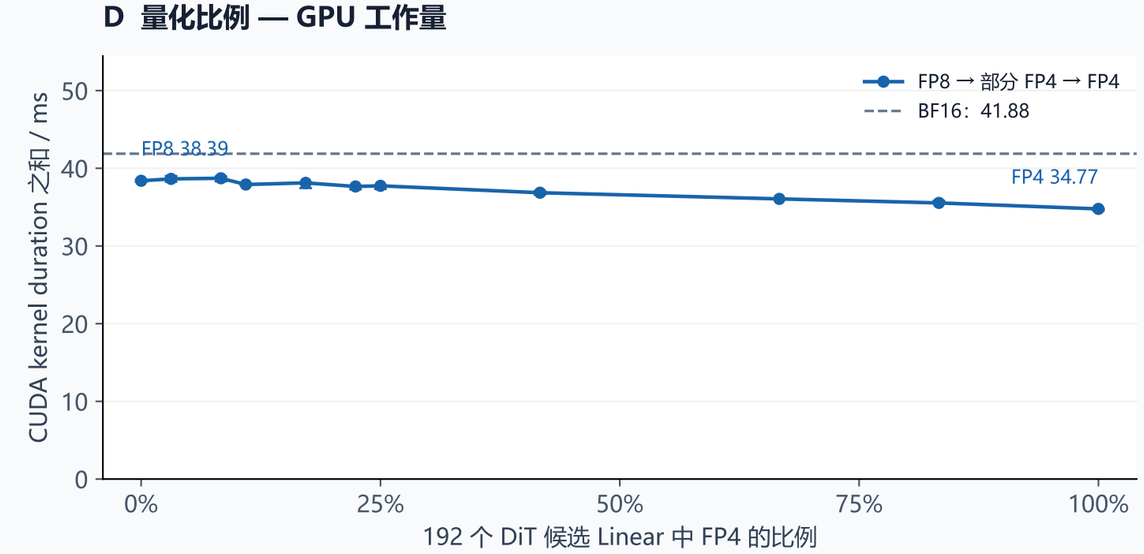
B 量化比例 — 闭环任务成功率



C 量化比例 — GEMM 占比



D 量化比例 — GPU 工作量



0% = 候选层全 FP8；100% = 候选层全 FP4；候选外模型层保持 BF16。BF16 虚线为融合未量化对照。

A / C / D：复用 10 月 13 日性能采样，观测 EMC 3200 MHz 子集；误差条为访问中位数 min–max，不是置信区间。

B：LIBERO-Spatial，20 Hz 固定延迟（视觉 3 tick、动作 1 tick）；每任务 3 个固定状态，仅作描述性初步结果。

单次调用墙钟时间与 profiler GPU 工作量分别统计、不相加；回合总耗时不用于性能曲线。没有锁频或平滑曲线。

完整 = 本轮计划的 360 回合已齐全；不表示质量等价、无损量化或完整任务质量验收。FP8 / FP4 成功率均低于 BF16。